# LLM红队实战：遗传算法进化24000种Prompt注入

发表于: 2026-9-27 17:32 96

## 遗传算法进化

随机生成50个个体，迭代5代：

- 适应度：成功输出禁止内容+1.0，部分绕过+0.5，拒绝0，触发警告-0.2
- 选择：保留top 20
- 交叉：策略基因交换
- 变异：随机换编码/包装器(10%概率)

实测结果：

- 第1代：直接注入，成功率12%
- 第2代：Base64编码，34%
- 第3代：翻译任务包装，45%
- 第4代：角色扮演+编码，68%
- 第5代：最优组合，成功率86.3%

## 防御建议

1. 输入层：检测编码混淆（Base64解码后再检测）
2. 对话层：检测多轮渐进式提取
3. 输出层：敏感信息过滤（API key/密码模式）
4. Agent层：工具调用白名单
5. 红队常态化：模型更新后跑进化测试

## 写在最后

大模型安全不是加个"我是AI"就完事。攻击者会进化，防御也要进化。遗传算法自动发现漏洞，比人工高效几个数量级。

合法使用：授权红队测试、自有模型评估、安全研究。未经授权测试他人系统违法。

项目开源地址：https://github.com/1ouxilisi/ai-security-agent-platform